



2020年智能系博士生答辩

# 大规模图的解构 及其在图挖掘任务中的应用

答辩人：吕天舒

导师：张岩 教授

2020.6.9



## 关系型数据与大规模图

### 多领域、大规模

- 线上社交网络、金融、生物、交通等

- 百万级

### 异构信息图

- 文本、标签、属性、图像、视频等


### 应用场景丰富

- 点分类: e. g. 用户画像

- 边预测: e. g. 好友推荐

- 图分类: e. g. 异常检测

截止至2020年1月，全世界最受欢迎的社交网络  
活跃用户数(百万)





# 引言 — 项目支持



- ✿ 国家重点基础研究计划(973)项目“**网络大数据计算的基础理论及其应用研究**”之课题“**网络大数据模式发现与效应分析方法研究**”(课题号:2014CB340405)
- ✿ 国家自然科学基金重点项目，面向课程的大规模在线教育资源组织与持续优化的理论与方法(课题号:61532001)
- ✿ 教育部---中国移动科研基金项目，慕课教学效果与慕课的教育资源质量评价体系及应用研究(课题号:MCM20170503)



# 引言 — 研究背景



研究课题

图挖掘



## 图挖掘



### 图的类型

1. 数学意义上的图  
(点集+边集)
2. 现实中的关系型数据  
(点集+边集+属性信息集)




### 挖掘方法

1. 图的表示方法+机器学习模型
2. 端到端训练






# 引言 — 研究难点






# 引言 — 研究问题





# 引言 - 主要工作





# 相关研究 – 图的表示方法



- 用向量表示图/边/节点，方便机器学习模型处理的数据形式
- 图的离散表示：社区发现
- 图的连续表示：网络表示学习、图神经网络




Fig. 图数据




Fig. 图的向量表示




Fig. 神经网络



# 相关研究 – 图的表示方法 – 社区发现



## 完全子图 [1]

- 简单易于理解
- 仅适用于读书分布平均的稠密图

## 非负矩阵分解 [2]

- 可解释性强
- 社区的重叠部分连接更加紧密

## 局部扩散及最优化 [3]

- 目标函数决定复杂度和质量
- 社区发现结果是冗余的

## 随机块模型 [4]

- 可解释性不强
- 算法假设比较少




Fig. 社区发现

[1] B. Adamcsek, G. Palla, I. J. Farkas, I. Derenyi, and T. Vicsek, "Cfinder: locating cliques and overlapping modules in biological networks," *Bioinformatics*, vol. 22, no. 8, pp. 1021–1023, 2006.

[2] J. Yang and J. Leskovec, "Overlapping community detection at scale: A nonnegative matrix factorization approach," in *WSDM'13*, pp. 587–596

[3] J. J. Whang, D. F. Gleich, and I. S. Dhillon, "Overlapping community detection using neighborhood-inflated seed expansion," *TKDE*, vol. 28, no. 5, pp. 1272–1284, 2016.

[4] P. K. Gopalan and D. M. Blei, "Efficient discovery of overlapping communities in massive networks," *PNAS*, vol. 110, no. 36, pp. 14 534– 14 539, 2013



# 相关研究 – 图的表示方法 – 图表示学习



| 算法           | 捕捉的结构性质   | 对应的子图       |
|--------------|-----------|-------------|
| DeepWalk [1] | 连接的紧密性    | 随机游走路径      |
| LINE [2]     | 一度、二度邻接关系 | 长度为1或2的短路径  |
| GraRep [3]   | 高度的邻接关系   | 直径为定长的子图    |
| SNS [4]      | 局部环境的相似性  | 节点数为3-5的小子图 |




Fig. 图表示学习

[1] Perozzi B, Al-Rfou R, Skiena S. Deepwalk: Online learning of social representations[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. ACM, 2014: 701-710.

[2] Tang J, Qu M, Wang M, et al. Line: Large-scale information network embedding[C]//Proceedings of the 24th International Conference on World Wide Web. International World Wide Web Conferences Steering Committee, 2015: 1067-1077.

[3] Cao S, Lu W, Xu Q. GraRep: Learning graph representations with global structural information[C]//Proceedings of the 24th ACM International Conference on Information and Knowledge Management. ACM, 2015: 891-900.

[4] Lyu T, Zhang Y, Zhang Y. Enhancing the network embedding quality with structural similarity[C]//Proceedings of the 2017 ACM on Conference on Information and Knowledge Management. ACM, 2017: 147-156.



# 相关研究 – 图的表示方法 – 图卷积网络



$$\mathbf{Z} = f\left(\tilde{\mathbf{D}}^{-1} \tilde{\mathbf{A}} \mathbf{X} \mathbf{W}\right)$$

| 计算步骤   | 含义            | 相关工作          |
|--|---------------|---------------|
| $\mathbf{XW}$  | 节点特征向量的线性变换   | GraphSAGE [1] |
| $\tilde{\mathbf{A}} \mathbf{X} \mathbf{W}$                                       | 节点邻域间传递信息     | GAT [2]       |
| $\tilde{\mathbf{D}}^{-1} \tilde{\mathbf{A}} \mathbf{X} \mathbf{W}$               | 归一化每个节点接收的信息  | DiffPool [3]  |
| $f\left(\tilde{\mathbf{D}}^{-1} \tilde{\mathbf{A}} \mathbf{X} \mathbf{W}\right)$ | 用非线性的激活函数处理信息 | DGCNN [4]     |




Fig. 2D卷积与图卷积

[1] Inductive Representation Learning on Large Graphs. W.L. Hamilton, R. Ying, and J. Leskovec arXiv:1706.02216 [cs.SI], 2017.

[2] P. Veličković, G. Cucurull, A. Casanova et al. "Graph attention networks". arXiv preprint arXiv:1710.10903, 2017.

[3] Ying, Zhitao, et al. "Hierarchical graph representation learning with differentiable pooling." *Advances in neural information processing systems*. 2018.

[4] Zhang, Muhan, et al. "An end-to-end deep learning architecture for graph classification." *Thirty-Second AAAI Conference on Artificial Intelligence*. 2018.

# 相关研究 – 解构策略

**定义 1(分治)** 设  $P$  是待求解的问题。将  $P$  归约为  $k$  个彼此独立的子问题  $P_1, P_2, \dots, P_k$ 。然后依此递归地求解这些子问题，得到解  $y_1, y_2, \dots, y_k$ 。最后将这  $k$  个解归并得到原问题的解。

## 解构策略的优势 [2,3]

- 提升分类效果
- 对大数据的高扩展性
- 提升可解释性
- 实现模块化
- 适于并行计算
- 提升模型选择的灵活度

[1] D. J. Miller and H. S. Uyar. "A mixture of experts classifier with learning based on both labelled and unlabelled data". In: Advances in neural information processing systems. 1997: 571–577.

[2] A. J. C. SHARKEY. "On combining artificial neural nets". Connection Science, 1996, 8(3-4): 299–314.

[3] L. Y. Pratt, J. Mostow, C. A. Kamm et al. "Direct Transfer of Learned Information Among Neural Networks." In: AAAI. 1991: 584–589.

异构网络的元路径 集成学习 MoE框架 ...




Fig. 神经网络中的解构策略举例:Mixture-of-Experts 框架 [1]



# 研究内容 — 图的解构策略 — 邻域解构



**定义 3 (邻域解构)** 设  $P$  是待求解的图挖掘问题。将  $P$  划分为  $k$  个彼此独立的子问题  $P_1, P_2, \dots, P_k$ ，每个子问题围绕着原图中包含目标节点的导出子图进行计算。整理子问题的解  $y_1, y_2, \dots, y_k$  可以得到原问题的解。

## 邻域解构：适用于节点属性的建模

- “物以类聚，人以群分”
- “近朱者赤，近墨者黑”
- 邻域解构应对**同质性形式多样**
  - 切断与非邻域节点的联系
  - 刻画节点地位
- 邻域解构缓解**图结构采集缺失**
  - 淡化邻域内部结构的影响
  - 扩大邻域




Fig. 邻域解构围绕目标节点的**k**-邻域进行计算



# 研究内容 – 图的解构策略 – 路径解构



**定义 2(路径解构)** 设  $P$  是待求解的图挖掘问题。将  $P$  划分为  $k$  个彼此独立的子问题  $P_1, P_2, \dots, P_k$ ，每个子问题围绕着的原图中的一条游走路径进行计算。整理子问题的解  $y_1, y_2, \dots, y_k$  可以得到原问题的解。

**路径解构：适用于节点对之间的关系建模**

• 基于最优路径刻画节点对关系的劣势

- 有悖实际情形
- 计算复杂

• 基于可行路径数目刻画节点对关系的劣势

- 忽略了中继节点的重要性

• 路径解构缓解图结构采集缺失

• 路径解构解决临近度计算复杂





Fig.路径解构围绕多条随机游走短路径进行计算

# 图挖掘中 邻域解构策略的运用





## 大规模网络上的重叠社区发现算法

### ✿ 基于博弈论的社区发现算法 – Fox

- ✿ **挑战:** 已有算法框架复杂度高
- ✿ **策略:** 关注个体与邻居的关系，快速计算
- ✿ **特点:** 符合潜博弈，保证算法收敛

### ✿ Fox与邻域解构

- ✿ 社区发现任务 → 判断一对邻接节点是否同属于一个社区
- ✿ 原始图 → 目标节点的自我网络




Fig. 用WCC指数刻画连接紧密程度



# 研究内容 – 邻域解构运用 – Fox



## 大规模网络上的重叠社区发现算法

### 相较于已有算法

- 更优的社区划分
- 更快的检测速度
- 更大的网络规模




Fig. 各个社区发现算法在不同数据集上的准确度




Fig. 迭代增加，移动的节点数目急速下降


| Dataset    | 3.9M 节点, 20.5M 边 |               |              |               | 22.5M 节点, 127.3M 边 |           |           |         |          |
|------------|------------------|---------------|--------------|---------------|--------------------|-----------|-----------|---------|----------|
|            | Algorithm        | time cost     | Density      | $w_c/w_i$     | $Q_{ov}$           | Algorithm | time cost | Density | $Q_{ov}$ |
| phone-call | BigCLAM          | 38 hr.        | 0.028        | 0.604         | <b>1.401</b>       | -         | -         | -       | -        |
|            | OSLOM            | 194 min       | 0.442        | 1.845         | 0.621              | -         | -         | -       | -        |
|            | FOX              | <b>14 min</b> | <b>0.607</b> | 2.920         | 0.758              | 238 min   | 0.529     | 1.044   |          |
|            | s-FOX            | 20 min        | 0.325        | <b>19.434</b> | 0.936              | 260 min   | 0.328     | 1.334   |          |

Table 各个社区发现算法在大规模网络上的表现



## 识别高影响力节点

- 差异性影响力最大化问题
  - 挑战：影响力高的节点组合在一起会相互影响
  - 对策：利用社区划分体现节点影响力的差异性
  - 特点：不是仅关注个体
- DIM与邻域解构
  - 图的离散表示的下游任务



*Diversified Influence Maximization*

**Authority** the expected cascade size

**Diversity** community similarity

| Single Node Influence |           | Node Set ( $k = 3$ ) Influence                   |           |
|-----------------------|-----------|--|-----------|
| Node                  | Influence | Node   | Influence |
| A                     | 7         | A, B <sub>1</sub> , C <sub>1</sub>               | 11        |
| B <sub>1</sub>        | 6.5       | A, B <sub>1</sub> , B <sub>2</sub>               | 9         |
| C <sub>1</sub>        | 6.5       | ...  | ...       |
| D <sub>1</sub>        | 6.5       | B <sub>1</sub> , C <sub>1</sub> , D <sub>1</sub> | 12.875    |
| ...                   | ...       | ...  | ...       |

Fig. 影响力最大化问题中需要考虑节点的diversity



## 识别高影响力节点

✿ 评判传播的多样性

✿ 演员共同出演的网络，包含演员国籍、影片等信息




Fig. 国籍覆盖度 (数值越高越好)




Fig. 影片覆盖度 (数值越高越好)





Fig. 密度 (数值越低越好)

# 图挖掘中 路径解构策略的运用





## 组合式图神经网络

### ① 基于组合泛化性的神经网络 — CNE

② 挑战：冷启动问题、异构图问题的根源

③ 对策：抛弃ID，利用节点属性

④ 特点：结构+属性 联合训练

### ⑤ CNE与路径解构

⑥ 刻画一对节点的关系 → 随机游走中，两个节点同时出现在窗口内的概率

⑦ 原始图 → 经过两个节点的一条随机游走路径



Fig. 图神经网络的两种框架：  
传统框架(上)与组合式框架(下)



# 研究内容 – 路径解构运用 – CNE



## 组合式图神经网络

### 相较于已有算法

- ◎ 一般图、冷启动节点、异构图上更优
- ◎ 特征向量反映结构信息

| 算法                 | 20%   |       |       | 40%   |       |       | 60%   |       |       | 80%   |       |       |
|--------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
|                    | P@10  | P@50  | P@100 |
| SGNS               | 0.033 | 0.011 | 0.007 | 0.034 | 0.011 | 0.007 | 0.035 | 0.012 | 0.007 | 0.036 | 0.012 | 0.007 |
| DeepWalk           | 0.093 | 0.032 | 0.019 | 0.099 | 0.038 | 0.023 | 0.095 | 0.037 | 0.023 | 0.090 | 0.036 | 0.022 |
| CANE               | 0.080 | 0.029 | 0.017 | 0.092 | 0.033 | 0.019 | 0.091 | 0.033 | 0.019 | 0.091 | 0.033 | 0.019 |
| TriDNR             | 0.065 | 0.022 | 0.013 | 0.068 | 0.024 | 0.014 | 0.078 | 0.028 | 0.016 | 0.078 | 0.029 | 0.017 |
| GraphSAGE          | 0.056 | 0.020 | 0.012 | 0.063 | 0.024 | 0.014 | 0.067 | 0.026 | 0.016 | 0.068 | 0.027 | 0.016 |
| CNE                | 0.081 | 0.029 | 0.019 | 0.085 | 0.034 | 0.022 | 0.083 | 0.033 | 0.024 | 0.082 | 0.036 | 0.030 |
| CNE <sub>MUL</sub> | 0.120 | 0.040 | 0.022 | 0.128 | 0.041 | 0.022 | 0.134 | 0.047 | 0.027 | 0.136 | 0.054 | 0.033 |

Table 边异构网络中的边预测任务准确率

|              | Rank | Product Title  |
|--------------|------|--|
| Click Record | 1    | Spring green loose mid-sleeve casual T-shirt.          |
|              | 2    | Pierced lace off shoulder 3/4 sleeve loose blouse.     |
|              | 3    | Plus size floral printed slimming princess dresses.    |
|              | 4    | Fake-two-piece pierced lace flowy tank blouse.         |
| DeepWalk     | 1    | Cotton plain loose white t-shirt.                      |
|              | 2    | Spring and summer outlet high-waist shorts.            |
|              | 3    | Ethnic style Thailand Napal summer holiday long dress. |
| CANE         | 1    | Original design fashion loose hip pants.               |
|              | 2    | Ethnic style Thailand Napal summer holiday long dress. |
|              | 3    | Summer sleeveless wrinkled dress.                      |
| TriDNR       | 1    | Puff sleeve elegant floral printed blouse.             |
|              | 2    | Extra size slimming pierced long scarf wrap shawl.     |
|              | 3    | Spring and summer sleeveless casual jumpsuits.         |
| GraphSAGE    | 1    | Korean summer beautiful dress.                         |
|              | 2    | Hong-kong embroidery dress.                            |
|              | 3    | Korean summer fashion v-neck hoodie.                   |
| CNE          | 1    | Summer flower figure-flattering princess dress.        |
|              | 2    | Slimming cold shoulder empire waist fairy dress.       |
|              | 3    | Pink colorful dotted silk long-sleeve blouse.          |

相邻词义的词语背景色是一致的。( large size , casual , feminine , hot weather )

Fig. 根据用户的点击历史预测接下来的点击



## 提出新节点中心度

### ✿ 基于随机游走的节点中心度 – NC

- ✿ 挑战：理想路径复杂度高

- ✿ 对策：随机游走重返一个节点的概率

- ✿ 特点：可利用图表示学习的结果

### ✿ NC与路径解构

- ✿ 利用DeepWalk的结果近似计算




Fig. NC(上图)低的点：度数(左图)低，中介数(右图)高



# 研究内容 – 路径解构运用 – Node Conductance



## 提出新节点中心度

- ◎相较于已有中心度
  - ◎有一定差异性
  - ◎适用于大规模网络
  - ◎与节点的活跃度、新边生成更为相关

D: 335K节点, 926K边 | A: 1M节点, 3M边 | Y: 317K节点, 1M边

| 数据集     | AP <sup>1</sup> | NC <sup>2</sup> | AB <sup>3</sup> | AE <sup>4</sup> | SC <sup>5</sup> | FB <sup>6</sup> |
|---------|-----------------|-----------------|-----------------|-----------------|-----------------|-----------------|
| DBLP    | 914             | 985             | 14268           | —               | —               | —               |
| Amazon  | 941             | 988             | 9504            | —               | —               | —               |
| Youtube | 2883            | 3464            | 168737          | —               | —               | —               |

<sup>1</sup> approximate PageRank. <sup>2</sup> Node Conductance.

<sup>3</sup> approximate Betweenness. <sup>4</sup> approximate Eigenvector Centrality.

<sup>5</sup> Subgraph Centrality. <sup>6</sup> Network Flow Betweenness.

Table 全局节点中心度的运行时间





Fig. 节点所属的社区数目与节点的不同中心度

# 图挖掘中邻域解构与路径解构策略的运用





## 捕捉节点地位信息的图表示学习

### ① 基于特殊小子图的图表示学习 – SNS

- 挑战：鲜有方法关注节点地位的刻画
- 对策：对节点的邻域进行建模
- 特点：邻域拆解为特殊小子图

### ② SNS与两种解构

- 路径解构：节点对连接紧密程度的建模
- 邻域解构：节点地位的建模




Fig. 节点的两种相似性




Fig. 用于刻画节点地位的特殊小子图



# 研究内容 – 两种解构综合运用 – SNS



## 捕捉节点地位信息的图表示学习

- 相较于已有算法
  - 表示向量可捕捉地位相似性
  - 更高的节点分类准确率




Fig. Sns的表示向量可以捕捉节点的地位相似性




Fig. 节点分类任务的Macro-F1和Micro-F1



## 识别跨结构洞节点

### 基于随机游走的结构表示 – RWSig

- 挑战：统计子图刻画结构复杂度高
- 对策：将节点邻域拆解为游走路径
- 特点：步骤简单高效，有图谱理论支撑

### RWSig与两种解构

- 邻域解构：节点地位的建模
- 路径解构：邻域节点关系的建模




Fig. 利用随机游走访问次数构造表示向量



# 研究内容 – 两种解构综合运用 – RWSig



## 识别跨结构洞节点

### 相较于已有算法

- 提升跨结构洞节点的判断准确率
- 对不活跃节点的判断更准确

335K节点, 926K边

| 方法     | 指标    | 0.01        | 0.02        | 0.03        | 0.04        | 0.05        | 0.06        | 0.07        | 0.08        | 0.09        |
|--------|-------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
| dw+sig | macro | <b>0.44</b> | <b>0.45</b> | <b>0.45</b> | <b>0.45</b> | <b>0.46</b> | <b>0.46</b> | <b>0.46</b> | <b>0.46</b> | <b>0.46</b> |
|        | micro | <b>0.45</b> | <b>0.45</b> | <b>0.46</b> |
| sig    | macro | 0.3         | 0.31        | 0.31        | 0.31        | 0.31        | 0.31        | 0.31        | 0.31        | 0.31        |
|        | micro | 0.39        | 0.4         | 0.4         | 0.39        | 0.39        | 0.4         | 0.4         | 0.39        | 0.39        |
| dw     | macro | 0.36        | 0.37        | 0.37        | 0.37        | 0.37        | 0.37        | 0.38        | 0.38        | 0.38        |
|        | micro | 0.37        | 0.37        | 0.38        | 0.38        | 0.38        | 0.38        | 0.38        | 0.38        | 0.38        |

Table DeepWalk结合RWSig, 识别结构洞节点的能力更强




Fig. 混淆矩阵, 判断不活跃节点更依赖RWSig



# 结语



- ✿ 邻域解构的运用
- ✿ 路径解构的运用
- ✿ 邻域解构和路径解构的综合运用

| 图挖掘任务中的挑战 | 解构策略赋予算法的能力 |
|-----------|-------------|
| 同质性形式多样   | 深入挖掘邻接关系的能力 |
| 图结构信息缺失   | 组合的泛化能力     |
| 临近度计算复杂   | 化繁为简的能力     |





Fig. 图挖掘中的宏观(macro)方法和微观(micro)方法



# 在学期间研究成果



1. [TSC 已接收] **Tianshu Lyu**, Lidong Bing, Zhao Zhang, Yan Zhang . FOX: Fast Overlapping Community Detection Algorithm in Big Weighted Networks
2. [PAKDD'20] **Tianshu Lyu**, Fei Sun, Yan Zhang. Node Conductance: A Scalable Node Centrality Measure Based on Deepwalk.
3. [RecSys'19] **Tianshu Lyu**, Fei Sun, Peng Jiang, Wenwu Ou, Yan Zhang. Compositional Network Embedding for Link Prediction.
4. [CIKM'17] **Tianshu Lyu**, Yuan Zhang, Yan Zhang. Enhancing the Network Embedding Quality with Structural Similarity.
5. [ICDM'16] **Tianshu Lyu**, Lidong Bing, Zhao Zhang, Yan Zhang. Efficient and Scalable Detection of Overlapping Communities in Big Networks.
6. [WISE'18] Xiaoxuan Ren, **Tianshu Lyu**, Zhao Zhang, Yan Zhang. PUB: Product Recommendation with Users' Buying Intents on Microblogs.
7. [AAAI'18] Yuan Zhang, **Tianshu Lyu**, Yan Zhang. COSINE: Community-Preserving Social Network Embedding from Information Diffusion Cascades.
8. [SIGIR'17] Yuan Zhang, **Tianshu Lyu**, Yan Zhang. Hierarchical Community-Level Information Diffusion Modeling in Social Networks.
9. 《百面深度学习》, 第三章 图神经网络, 人民邮电出版社



2020年智能系博士生答辩

感谢！  
请各位老师批评指正

答辩人：吕天舒  
导师：张岩 教授

2020.4.15